

AI 产品项目复盘与全生命周期研发 SOP

基于多个 AI 产品项目的实践经验沉淀

项目	说明
文档版本	v0.2
适用场景	AI 工作流、Agent 应用与文档自动化
涉及角色	产品经理、前端开发、后端开发、Agent/算法开发、测试、运营及项目协作方
定位	既是项目复盘，也是后续 AI 产品项目的协作 SOP 与方法论草案。

核心共识

AI 产品项目不是普通功能开发外接一个模型接口，而是同时管理产品体验、数据上下文、Agent 行为、工程稳定性和效果评测的协作过程。AI 产品本质是持续优化系统，而不是一次性交付。

一、为什么要沉淀这套 AI SOP

在多个 AI 项目的实践中，项目类型虽然不同，但推进过程会暴露出一些共性问题。沉淀 SOP 的目的，不是增加流程负担，而是把已经踩过的坑变成团队后续协作的默认动作。

共性问题	对项目的影响	SOP 中的对应机制
产品方案确定后才发现数据拿不到或数据质量不稳定	方案返工，Agent 效果难以达到预期	数据准备前置、AI Spec 明确上下文和数据边界
Prompt 到开发阶段频繁调整	产品、Agent、开发之间反复拉齐，成本高	Prompt / Agent 版本管理，先用 Demo 和 Golden Standard 评估
AI 输出没有统一评测标准	上线判断依赖主观感受，难以复盘	建立 Golden Standard、人工评测表和通过标准
测试阶段只测功能，没有测 AI 效果	功能可用但结果不可用，用户信任度不足	功能测试 + AI 输出质量评测 + 数据验证并行

共性问题	对项目的影响	SOP 中的对应机制
上线以后缺少效果监控	无法判断是否值得继续投入和优化	上线指标看板、采纳率/失败率/成本监控、复盘机制

二、AI 产品全生命周期闭环

建议将 AI 产品项目统一拆成 7 个主阶段，并在上线后进入数据回流和下一版本优化。前 4 个阶段解决“做什么、为什么做、怎么做”的问题，后 3 个阶段解决“如何实现、如何验证、如何持续优化”的问题。



图 1：AI 产品全生命周期闭环

阶段	名称	核心目标	主要产出	通过标准
1	需求分析与价值初判	判断需求是否真实、是否值得做、AI 是否能做、AI 是否适合做	需求分析文档、价值判断、AI 适配度结论	场景真实、价值明确、AI 有必要性
2	市场与竞品调研	明确外部解法、体验基准和差异化方向	竞品调研报告、可借鉴点、差异化机会	知道别人怎么做，也知道我们应该怎样做
3	产品方案设计与数据准备	把需求转化为可开发、可验证的产品方案	原型、PRD、AI_Spec、开发/测试/验证数据、Golden Standard、数据埋点方案	产品流程清楚，数据边界清楚，开发能理解并评估
4	Agent 设计与技术方案评审	确认 AI 能力如何实现，以及工程上是否可行	Agent Demo、Agent 设计文档、技术方案、接口文档、排期评估	方案可实现，风险可控，成本可接受

阶段	名称	核心目标	主要产出	通过标准
5	产品前后端开发 + Agent 开发	完成功能闭环和 AI 能力实现	可测试版本、接口实现、Agent/ Prompt 配置、调用日志、灰度/开关配置	主流程跑通，AI 能力可调用，关键日志可追踪
6	功能测试及数据验证	验证功能可用、AI 输出可信、数据安全	测试报告、数据验证记录、AI 评测表、人工评测报告、问题清单、优化建议、上线建议	功能稳定，AI 输出达标，无高风险问题
7	上线、监控与复盘	观察真实使用效果，并沉淀经验	上线记录、指标看板、用户反馈、复盘报告、Prompt/Agent 优化记录	有数据可看，有问题可追，有经验可复用

三、AI Spec 标准模板

AI_Spec 是 PRD 的配套文档，用于定义 AI 能力边界、输入输出、上下文、模型、工具、约束和评测方式。它让产品、Agent、开发、测试对同一件事形成可执行共识。

模块	需要说明的内容
目标	AI 需要完成什么任务，服务什么用户场景，输出对业务有什么价值。
输入 Input	用户输入、业务上下文、历史数据、工具返回、上下文裁剪规则。
输出 Output	输出格式、JSON Schema、字段定义、异常输出、用户确认/编辑/撤销机制。
模型 Model	模型选择、调用方式、备用模型、模型升级策略、成本和延迟预估。
Prompt	System Prompt、User Prompt、Few-shot 示例、Prompt 版本记录。
Tool	Function Calling、MCP、知识库、业务接口、工具权限和失败处理。
约束 Guardrail	禁止输出、权限控制、Token 限制、敏感数据处理、人工确认边界。
评测 Evaluation	Golden Standard、准确性、完整性、稳定性、Latency、Cost、通过标准。

四、Golden Standard 建设标准

Golden Standard 是 AI 项目的核心资产，用于回答 “AI 输出到底好不好”。它不是测试阶段临时造几条样例，而是在方案阶段就开始建设，并在每次 Prompt 修改、模型升级或 Agent 流程调整后重新评测。

组成	建议标准
真实 Case	优先来自真实用户场景，早期可从 30-50 条起步，成熟能力逐步沉淀到 100-500 条。
标准答案	为每个 Case 标注理想输出、关键事实、禁止出现的错误和可接受变体。
评分规则	至少包含准确性、完整性、稳定性、业务可接受度、幻觉/越权风险。
人工标注	由产品、业务方、测试共同参与，避免只从技术视角判断。
触发时机	上线前、每次 Prompt 修改、每次模型升级、每次工具或上下文逻辑调整后都重新跑评测。

五、角色分工建议

角色	主要职责
项目经理	负责项目总体进度、成本、质量管理，协调资源、拉齐团队认知。
产品经理	负责需求判断、竞品调研、产品方案、PRD、AI_Spec、Agent Demo 设计、验收标准、Agent 评测方案。
前端开发	负责 AI 能力入口、交互状态、结果展示、用户确认、编辑、重试和异常反馈体验。
后端开发	负责接口、数据读取与写入、权限校验、业务规则、日志、灰度、开关和回滚能力。
Agent 开发	负责 Agent workflow、Context 管理、Memory、Long Context、Tool Routing、Fallback、Prompt、模型选择、输出 Schema、评测优化和版本管理。
测试	负责功能测试、权限测试、异常测试、AI 样例评测、数据验证和上线质量判断。
运营/业务方	负责真实场景反馈、试点用户组织、效果观察、案例沉淀和后续推广建议。

六、关键交付物建议

交付物	所属阶段	用途
需求分析文档	阶段 1	说明为什么做、为谁做、解决什么问题，以及是否适合用 AI。
竞品调研报告	阶段 2	提供外部参考、体验基准和差异化依据。
PRD / 原型	阶段 3	定义产品流程、页面交互、业务规则和用户操作闭环。
Golden Standard / 评测集	阶段 3	作为标准用于评估 AI 输出质量，支撑上线前和迭代后的效果判断。
AI_Spec	阶段 3-4	定义 AI 能力边界、输入输出、上下文、Agent 行为和评测标准。
Agent 设计文档 / 技术方案	阶段 4	定义 Agent workflow、模型、工具、接口、权限、日志、成本和回滚。
埋点与监控方案	阶段 3/7	定义上线后要看的调用率、采纳率、失败率、成本、延迟等指标。
测试与复盘报告	阶段 6-7	验证上线质量，并沉淀后续优化经验。

七、AI 项目风险治理

风险	典型表现	应对机制
Prompt 失效	同类输入输出不稳定，修改一处影响其他场景	Prompt 版本管理、Golden Standard 回归评测
模型升级效果下降	模型替换后准确率、风格或工具调用行为变化	A/B 评测、灰度切换、回滚策略
Token 成本上涨	调用量上升或上下文过长导致成本不可控	成本监控、上下文裁剪、缓存和分层模型策略
幻觉	输出不存在的事实、任务或结论	引用依据、结构化输出、Golden Standard、人工确认
延迟过高	用户等待时间长，影响转化和采纳	Streaming、异步任务、缓存、模型分层
工具调用失败	Agent 调接口失败、参数错误或重复执行	Retry、幂等设计、Fallback、错误日志和告警
越权或数据泄露	读取了用户无权访问的数据或暴露敏感信息	服务端权限校验、数据脱敏、审计日志

八、上线监控指标

AI 产品上线后要持续看“有没有人用、结果能不能用、成本是否可控、哪里需要优化”。建议在灰度阶段就建立效果看板。

指标	说明
AI 调用率	目标用户中有多少人实际触发 AI 能力。
AI 采纳率	AI 输出被直接采纳或部分采纳的比例。
一次成功率	用户一次调用后即可完成任务的比例。
Retry 率	用户重复生成或重新调用的比例，用于判断输出稳定性。
用户编辑率	用户对 AI 输出进行修改的比例，用于判断可用性和可信度。
失败率	模型调用、工具调用、解析、权限等失败比例。
人工介入率	需要人工确认、修正或兜底的比例。
Latency	端到端响应耗时，尤其关注 P50 / P90 / P95。
Token 成本	单次调用成本、总成本、按用户/功能/模型拆分的成本。

九、关键原则建议

原则	说明
先判断价值，再进入方案	AI 项目不要因为“能做”就做，而要先证明场景真实、价值明确、失败可控。
数据准备前置	在产品方案阶段就明确数据来源、结构、权限和测试样例，避免开发后期才发现数据不可用。
AI Spec 先于开发	在进入开发前先定义输入、输出、上下文、工具、约束和评测标准。
Context 比 Prompt 更关键	复杂 AI 项目中，效果往往取决于上下文管理、工具路由和数据质量，而不只是 Prompt 文案。
测试覆盖 AI 输出质量	AI 产品不仅要测功能，还要测准确性、完整性、稳定性、幻觉、越权和业务可接受度。
上线后持续复盘	通过真实数据观察使用率、采纳率、失败率和成本，把每个项目变成下一次项目的资产。